

王召德

AI 推理引擎专家 · 端侧大模型 · 高性能计算
hi@zhaode.wang · github.com/wangzhaode

教育经历

中国科学院计算技术研究所 计算机体系结构国家重点实验室	计算机体系结构硕士	2017 – 2020
山东大学	计算机科学与技术学士	2013 – 2017

工作经历

阿里巴巴 · 淘天集团	MNN 技术负责人	2020 – 至今
推理引擎: 负责 MNN 架构与性能优化, 覆盖 CPU、Metal、OpenCL、Vulkan、Hexagon、CoreML 和 NNAPI, 包括算子内核、内存规划、图优化及自动融合。 端侧大模型: 发起并负责 MNN-LLM, 支持 100+ 文本及多模态模型, 涵盖低比特与混合精度量化、KV Cache 与 Attention 优化、投机解码。 业务落地: 构建 MNN 端侧 Python 运行时, 支撑拍立淘、淘宝直播、安全、信息流等数十个算法; 推动 MNN 在手淘、闲鱼、夸克、千问等业务场景落地, 覆盖千万级用户, 并为钉钉、优酷、淘宝闪购和高德提供技术支持。 开发者生态: 建设端到端模型转换与部署能力、CV/音频模块、Python API 和 CI/CD; MNN GitHub Star 15.8K+。		
寒武纪科技	编译器工程师实习生	2018 – 2020
优化寒武纪加速器算子, 并参与编译器优化与链接器开发。		
旷视科技	算法工程师实习生	2019
优化交通视频理解算法, 并完成 C++ 工程化落地。		
微软亚洲工程院	软件工程师实习生	2016
调研 LevelDB、Presto 和 Hadoop 在广告数据存储与分析场景中的应用。		

代表性论文

深度参与		
Efficient LLM Inference on ARM via Hardware-Aware Operator Co-Design and Heuristic Mixed-Precision Search	ISCAS	2026
RecGPT-Mobile: On-Device Large Language Models for User Intent Understanding in Taobao Feed Recommendation	SIGIR	2026
MNN-LLM: A Generic Inference Engine for Fast Large Language Model Deployment on Mobile Devices	MM Asia	2024
Walle: An End-to-End, General-Purpose, and Large-Scale Production System for Device-Cloud Collaborative Machine Learning	OSDI	2022
合作研究		
ARC-Decode: Accelerated Decoding with Risk-Bounded Acceptance	ICML	2026
Prism-MoE: Efficient Dense-to-MoE Conversion for Visual Autoregressive Generation	ICML	2026
AccKV: Towards Efficient Audio-Video LLMs Inference via Adaptive-Focusing and Cross-Calibration KV Cache Optimization	AAAI	2026
VertiKV: Vertical-Integrity KV Cache Compression for Efficient Multimodal Long-Context Inference	ACM MM	2026
MadaKV: Adaptive Modality-Perception KV Cache Eviction for Efficient Multimodal Long-Context Inference	ACL	2025

专利与申请

BANG-Linker: 一种异构链接方法、装置及相关产品	寒武纪 · 已申请	2019
BANG 模拟器: 一种编程调试方法、装置及相关产品		
一种面向移动设备部署大语言模型的解决方案	阿里巴巴 · 已申请	2024
一种利用浮点零点自由度的显著性感知分块量化方法	阿里巴巴 · 申请中	2026
一种基于动作条件算子误差的低比特大语言模型混合精度量化分配方法		

荣誉与竞赛

IEEE AICAS Grand Challenge: LLM 软硬件系统协同优化	第一名	2024, 2025
国产 NPU 竞赛: 太初元基算子开发竞赛、算能 TPU 编程竞赛	第一名	2022, 2024

专业技能

编程语言	C、C++、Python、汇编、CUDA、OpenCL、Vulkan、Metal、BANG、Java、Objective-C
专业方向	编译器、AI 推理引擎、CPU/GPU/NPU 算子优化、模型转换、量化、大语言模型