

王召德

AI 推理引擎专家 · 端侧大模型 · 高性能计算
hi@zhaode.wang · github.com/wangzhaode

教育经历

中国科学院计算技术研究所 计算机体系结构国家重点实验室	计算机体系结构硕士	2017 – 2020
山东大学	计算机科学与技术学士	2013 – 2017

工作经历

阿里巴巴 · 淘天集团	高级技术专家 · MNN 技术负责人	2020 – 至今
MNN 核心架构: 负责 MNN 架构及异构硬件性能优化, 覆盖 ARM CPU、Metal/OpenCL/Vulkan GPU 与 Hexagon/CoreML/NNAPI 加速后端, 包括算子内核、内存规划、图优化与融合、模型转换。 端侧 AI 平台: 构建端侧 Python 运行时和端到端部署体系, 支撑拍立淘、淘宝直播、安全、信息流等数十个算法, 并服务夸克、千问、钉钉、优酷、淘宝闪购和高德等业务; MNN GitHub Star 15.8K+。 MNN-LLM 与业务: 发起并负责 MNN-LLM, 支持 100+ 文本及多模态模型, 覆盖 2/3/4/8-bit 与混合精度量化、KV Cache 与 Attention 优化、投机解码; 推动端侧大模型在手淘、闲鱼搜推场景落地, 覆盖千万级用户。 端侧 SLM: 带领团队从零训练面向端侧业务的 0.3B SLM, 覆盖数据采集与质量评估、预训练、SFT、RL 和端到端模型评测。		
寒武纪科技	编译器工程师实习生	2018 – 2020
从事寒武纪 BANG 编译器与链接器研发, 重点参与异构链接能力建设; 并基于 Caffe 优化寒武纪 MLU 算子性能。		
旷视科技	算法工程师实习生	2019
优化交通视频理解算法, 并完成 C++ 工程化落地。		
微软亚洲工程院	软件工程师实习生	2016
调研 LevelDB、Presto 和 Hadoop 在广告数据存储与分析场景中的应用。		

代表性论文

深度参与		
Efficient LLM Inference on ARM via Hardware-Aware Operator Co-Design and Heuristic Mixed-Precision Search	ISCAS	2026
RecGPT-Mobile: On-Device Large Language Models for User Intent Understanding in Taobao Feed Recommendation	SIGIR	2026
MNN-LLM: A Generic Inference Engine for Fast Large Language Model Deployment on Mobile Devices	MM Asia	2024
Walle: An End-to-End, General-Purpose, and Large-Scale Production System for Device-Cloud Collaborative Machine Learning	OSDI	2022
合作研究		
LISA: Locality-Informed Speculative Decoding for Accelerating Autoregressive Image Generation	ECCV	2026
ARC-Decode: Accelerated Decoding with Risk-Bounded Acceptance	ICML	2026
Prism-MoE: Efficient Dense-to-MoE Conversion for Visual Autoregressive Generation	ICML	2026
AccKV: Towards Efficient Audio-Video LLMs Inference via Adaptive-Focusing and Cross-Calibration KV Cache Optimization	AAAI	2026
VertiKV: Vertical-Integrity KV Cache Compression for Efficient Multimodal Long-Context Inference	ACM MM	2026
MadaKV: Adaptive Modality-Perception KV Cache Eviction for Efficient Multimodal Long-Context Inference	ACL	2025

专利与申请

BANG-Linker: 一种异构链接方法、装置及相关产品	寒武纪 · 已申请	2019
BANG 模拟器: 一种编程调试方法、装置及相关产品		
一种面向移动设备部署大语言模型的解决方案	阿里巴巴 · 已申请	2024
一种利用浮点零点自由度的显著性感知分块量化方法	阿里巴巴 · 申请中	2026
一种基于动作条件算子误差的低比特大语言模型混合精度量化分配方法		

荣誉与竞赛

IEEE AICAS Grand Challenge: LLM 软硬件系统协同优化	第一名	2024, 2025
国产 NPU 竞赛: 太初元基算子开发竞赛、算能 TPU 编程竞赛	第一名	2022, 2024

专业技能

编程语言	C、C++、Python、汇编、CUDA、OpenCL、Vulkan、Metal、BANG、Java、Objective-C
专业方向	编译器、AI 推理引擎、CPU/GPU/NPU 算子优化、模型转换、量化、大语言模型