

王召德

AI 推理引擎专家 · 端侧大模型 · 高性能计算

邮箱: hi@zhaode.wang · github.com/wangzhaode

教育经历

中国科学院计算技术研究所 计算机体系结构国家重点实验室	计算机体系结构硕士	2017 – 2020
山东大学	计算机科学与技术学士	2013 – 2017

工作经历

阿里巴巴 · 淘天集团	高级技术专家 · MNN 技术负责人	2020 – 至今
MNN 核心架构: 负责 MNN 核心架构与技术路线, 持续建设模型转换、计算图优化、内存规划、算子融合以及 CPU/GPU/NPU 后端, 形成覆盖模型导入、编译优化、执行与异构加速的完整端侧推理引擎, MNN GitHub Star 15.8K+。 MNN-LLM 工程化: 发起并负责 MNN-LLM, 建设模型转换与量化工具链、Runtime、Tokenizer、KV Cache、评测和 ModelZoo, 支持 200+ 语言与多模态模型, 下载超百万次; 围绕低内存、长上下文和生成速度, 落地低比特与混合精度量化、权重/KV Cache mmap、FlashAttention 和投机解码。 生产业务落地: 推动端侧大模型在手淘信息流、购后推荐、商品重排和闲鱼消息理解等场景上线, 覆盖千万级用户并取得业务正向收益; 除大模型外, MNN 的通用端侧推理能力还服务夸克、千问、钉钉、优酷、淘宝闪购和高德等业务。 端侧 SLM 研发: 带领团队从零训练面向端侧业务的 0.3B SLM, 打通数据、Tokenizer、预训练、SFT、RL、评测和 MNN 部署链路。 端侧 AI 平台: 针对算法依赖 Python/OpenCV/NumPy、移动端缺少统一运行环境的问题, 构建端侧 Python Runtime 以及模型转换、调试和发布链路, 支撑拍立淘、淘宝直播、安全、信息流等数十个算法; 核心 CV/NumPy API 性能平均提升 15%+, 直播 App 包体降低 13MB。 研发基础设施: 从零搭建 MNN 文档、跨平台 CI、精度/性能测评与 Crash 分析体系; 建设开发、测试、性能分析与问题定位的 Agent/Skill, 重点沉淀模型分析、适配、导出和验证 workflow, 使复杂模型适配由专家数天缩短至新人借助 AI 数小时。		
寒武纪科技	编译器工程师实习生	2018 – 2020
参与寒武纪 BANG 编译器与链接器研发, 重点参与异构链接能力建设; 并参与基于 Caffe 的 MLU 算子接入与性能优化。		
旷视科技	算法工程师实习生	2019
参与交通视频理解算法研究与优化, 重点包括车道线识别、基于单目摄像头的车速估计和交通标志识别。		
微软亚洲工程院	软件工程师实习生	2016
调研 LevelDB、Presto 和 Hadoop 在广告数据存储与分析场景中的应用。		

论文

Efficient LLM Inference on ARM via Hardware-Aware Operator Co-Design and Heuristic Mixed-Precision Search	ISCAS	2026
RecGPT-Mobile: On-Device Large Language Models for User Intent Understanding in Taobao Feed Recommendation	SIGIR	2026
MNN-LLM: A Generic Inference Engine for Fast Large Language Model Deployment on Mobile Devices	MM Asia	2024
Walle: An End-to-End, General-Purpose, and Large-Scale Production System for Device-Cloud Collaborative Machine Learning	OSDI	2022
LISA: Locality-Informed Speculative Decoding for Accelerating Autoregressive Image Generation	ECCV	2026
ARC-Decode: Accelerated Decoding with Risk-Bounded Acceptance	ICML	2026
Prism-MoE: Efficient Dense-to-MoE Conversion for Visual Autoregressive Generation	ICML	2026
AccqKV: Towards Efficient Audio-Video LLMs Inference via Adaptive-Focusing and Cross-Calibration KV Cache Optimization	AAAI	2026
VertiKV: Vertical-Integrity KV Cache Compression for Efficient Multimodal Long-Context Inference	ACM MM	2026
MadaKV: Adaptive Modality-Perception KV Cache Eviction for Efficient Multimodal Long-Context Inference	ACL	2025

专利与申请

BANG-Linker: 一种异构链接方法、装置及相关产品	寒武纪 · 已申请	2019
BANG 模拟器: 一种编程调试方法、装置及相关产品		
一种面向移动设备部署大语言模型的解决方案	阿里巴巴 · 已申请	2024
一种利用浮点零点自由度的显著性感知分块量化方法	阿里巴巴 · 申请中	2026
一种基于动作条件算子误差的低比特大语言模型混合精度量化分配方法		

荣誉与竞赛

IEEE AICAS Grand Challenge: LLM 软硬件系统协同优化	第一名	2024, 2025
国产 NPU 竞赛: 太初元基算子开发竞赛、算能 TPU 编程竞赛	第一名	2022, 2024

专业技能

编程语言	C、C++、Python、汇编、CUDA、OpenCL、Vulkan、Metal、BANG、Java、Objective-C
专业方向	编译器、AI 推理引擎、CPU/GPU/NPU 算子优化、模型转换、量化、大语言模型